Tugas 2 Individu - Preprocessing

Analisis dan Preprocessing Data

Pengantar Data Sains



Disusun Oleh:

Michael Alexander Newton 105224017

PROGRAM STUDI ILMU KOMPUTER

FAKULTAS SAINS DAN ILMU KOMPUTER

UNIVERSITAS PERTAMINA

2026

Soal 1

1. Pendahuluan & Kerangka Metodologi

Laporan ini menjelaskan proses pembersihan dan penyiapan data (data preprocessing) secara menyeluruh terhadap dataset pengangkutan sampah harian di DKI Jakarta. Prosedur ini mengacu pada kerangka kerja CRISP-DM (Cross-Industry Standard Process for Data Mining), yang difokuskan pada dua tahapan utama:

- Data Understanding: Menganalisis struktur dataset, tipe data setiap kolom, keberadaan data hilang (missing values), noise atau karakter non-standar, serta inkonsistensi antar-variabel.
- Data Preparation: Melakukan konversi tipe data ke bentuk numerik/kategorikal yang tepat, pembersihan teks, penyeragaman satuan dimensi, serta penerapan strategi imputasi terstruktur yang adaptif terhadap karakteristik setiap variabel.

Diagram Alur (Flowchart) Langkah Pengerjaan Preprocessing Data — Soal 1

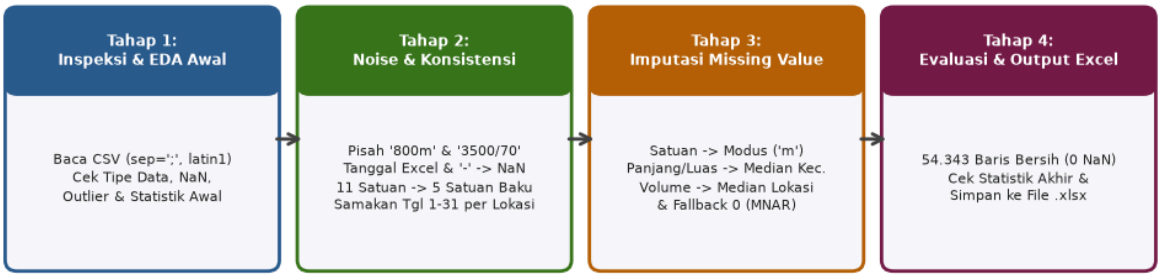


Diagram di atas menggambarkan urutan langkah pengerjaan *preprocessing* data secara sistematis dari kondisi data mentah hingga menjadi dataset bersih yang terbagi ke dalam 4 tahapan berurutan:

1. **Tahap 1 Inspeksi & EDA Awal (*Data Understanding*):** Proses dimulai dengan membaca berkas CSV mentah menggunakan pemisah titik koma (sep=';') dan penyandian encoding='latin1', serta menghapus spasi tersembunyi pada nama kolom. Selanjutnya dilakukan inspeksi tipe data, pemetaan keberadaan *missing values* dan *noise* di seluruh 8 variabel, serta identifikasi statistik deskriptif (Mean, Median, Modus, dan deteksi *outlier* menggunakan Boxplot) sebagai dasar pemilihan metode imputasi.

2. **Tahap 2 Pembersihan Noise & Konsistensi Kolom (*Data Cleaning & Consistency*):** Sesuai petunjuk soal, langkah konsistensi dilakukan terlebih dahulu sebelum pengisian *missing values*. Proses ini mencakup pemisahan satuan yang menempel pada angka (800m, 1Ha) ke kolom satuan_panjang/luas, pengambilan angka panjang utama pada format garis miring Panjang/Lebar (3500/70), penyeragaman 11 variasi penulisan satuan menjadi 5 satuan baku (m, Ha, m2, m3, km), serta penyelarasan nilai ukuran dan satuan dari tanggal 1 ke tanggal 2–31 pada titik lokasi yang sama (termasuk perbaikan desimal 1.36 → 1360 m di Kec. Kebon Jeruk). Terakhir, teks korup tanggal Excel (Apr-00, dll.), *typo* 'O.5', dan 17.702 simbol strip ('-', '\x97', ' ') dikonversi menjadi nilai kosong standar (NaN) dan tipe kolom diubah menjadi float64.
3. **Tahap 3 Imputasi Missing Values (*Handling Missing Values*):** Setelah data konsisten dan seluruh *noise* berubah menjadi NaN, dilakukan pengisian nilai kosong secara bertingkat: sisa kolom satuan_panjang/luas yang kosong diisi dengan Modus ('m'), kolom panjang/luas pada lokasi Saringan Sampah diisi menggunakan Median per Kecamatan, dan kolom volume_sampah_perhari(m3) diisi menggunakan Median harian per Titik Lokasi (dengan *fallback* nilai 0 untuk lokasi yang tercatat kosong/strip selama 31 hari penuh berdasarkan asumsi *Missing Not At Random* / MNAR).
4. **Tahap 4 Evaluasi & Output Excel (*Final Evaluation & Export*):** Tahap terakhir adalah memverifikasi bahwa seluruh 54.343 baris dan 8 kolom telah bersih 100% (0 *missing values*), mengevaluasi perbandingan statistik deskriptif sebelum dan sesudah *preprocessing*, serta mengekspor dataset akhir ke dalam berkas Excel (volume_pengangkutan_sampah_preprocessed.xlsx).

2. Tahap 1: Inspeksi Data Mentah & Deskripsi Variabel

Tahap awal berfokus pada identifikasi atribut dataset, pemeriksaan nilai yang hilang, dan penanganan inkonsistensi data. Pemrosesan dilakukan dengan bahasa pemrograman Python menggunakan beberapa pustaka utama:

- pandas: Digunakan untuk pemrosesan tabel data, meliputi pembacaan berkas CSV, inspeksi struktur, pembersihan teks/angka, imputasi data hilang, hingga ekspor hasil pembersihan.

- numpy: Digunakan untuk menandai noise sebagai nilai hilang standar (np.nan) serta menangani operasi numerik.
- matplotlib.pyplot & seaborn: Digunakan untuk membuat visualisasi perbandingan data sebelum dan sesudah tahap preprocessing.

Berkas CSV dibaca menggunakan pemisah titik koma (sep=';') dan penyandian encoding='latin1' guna mengakomodasi karakter khusus seperti simbol pangkat. Spasi tambahan (whitespace) pada nama kolom juga dibersihkan untuk mencegah galat akses variabel.

Deskripsi Variabel Dataset:

Dataset memuat 54.343 baris (mencakup 1.753 titik lokasi selama 31 hari pada bulan Januari 2021) dan 8 variabel dengan rincian sebagai berikut:

No	Nama Variabel	Tipe Data Seharusnya	Deskripsi & Arti Variabel
1	bulan	Numerik (int64)	Bulan pencatatan pengangkutan sampah (1 = Januari).
2	titik_lokasi	Kategorikal (object)	Nama spesifik lokasi kali, sungai, situ, waduk, atau saringan sampah yang ditangani.
3	kecamatan	Kategorikal (object)	Wilayah administrasi tingkat kecamatan tempat titik lokasi berada.
4	wilayah	Kategorikal (object)	Wilayah Kota Administrasi di Provinsi DKI Jakarta (Jakarta Pusat, Utara, Barat, Selatan, Timur).
5	panjang/luas	Numerik (float64)	Ukuran dimensi fisik panjang ruas kali/saluran atau luas situ/waduk.
6	satuan_panjang/luas	Kategorikal (object)	Satuan ukuran yang menerangkan nilai pada kolom panjang/luas (m, Ha, m2, m3, km).
7	tanggal	Numerik (int64)	Tanggal pencatatan harian di bulan Januari (bernilai 1 sampai 31).
8	volume_sampah_perhari(m3)	Numerik (float64)	Jumlah volume sampah yang berhasil diangkut per hari dalam satuan meter kubik (m^3).

2.1 Tabel Deskripsi Variabel & Hasil Inspeksi Awal

Berikut adalah tabel ringkasan deskripsi variabel beserta hasil inspeksi awal terhadap tipe data, jumlah data non-null, nilai kosong (NaN), persentase NaN, jumlah nilai unik, dan contoh sampel isinya:

No	Nama Variabel	Tipe Data Awal	Non-Null Count	Missing (NaN) Awal	Persentase NaN (%)	Jumlah Nilai Unik	Contoh Isi (Sampel)	Deskripsi Variabel
1	bulan	int64	54.343	0	0,00%	1	[1]	Bulan pencatatan data pengangkutan sampah (1 = Januari)
2	titik_lokasi	object	54.343	0	0,00%	1.737	[Kali / Sungai Sentiong - Ruas Jl. Tanah Tinggi, ...]	Nama lokasi kali, sungai, situ, waduk, atau saringan sampah
3	kecamatan	object	54.343	0	0,00%	42	[Johar Baru, Kemayoran, Senen, Sawah Besar, Gambir]	Nama wilayah kecamatan dari titik lokasi
4	wilayah	object	54.343	0	0,00%	5	[Jakarta Pusat, Jakarta Utara, Jakarta Barat, ...]	Nama Kota Administrasi di DKI Jakarta

5	panjang/luas	object	53.475	868	1,60%	390	[1260, 1280, 1990, 800m, 3500/70, Apr-00]	Ukuran dimensi fisik panjang atau luas titik lokasi
6	satuan_panjang/luas	object	32.388	21.955	40,40%	11	[m, M, Ha, H, HA, hektar, Hektar, m2, m², M³, km]	Satuan ukuran dari kolom panjang/luas
7	tanggal	int64	54.343	0	0,00%	31	[1, 2, 3, 4, 5]	Tanggal pencatatan harian di bulan Januari (1 s.d. 31)
8	volume_sampah_perhari(m3)	object	54.343	0* (17.702 strip)	0,00%*	257	[4, 7, 1, -, O.5]	Volume sampah yang diangkut per hari dalam satuan meter kubik (m^3)

2.2 Identifikasi Statistik Deskriptif Lengkap (EDA Awal)

Analisis Data Eksploratif (EDA) awal dilakukan untuk memahami karakteristik statistik dataset sebelum pembersihan dan menjadi dasar pemilihan metode pengisian missing values:

a) Statistik Deskriptif Variabel Kategorikal

- wilayah: Terdiri dari 5 Kota Administrasi dengan frekuensi pencatatan tertinggi berada di Jakarta Barat (17.205 baris / 31,66%), diikuti Jakarta Selatan, Jakarta Timur, Jakarta Utara, dan Jakarta Pusat.
- kecamatan: Terdiri dari 42 kecamatan di DKI Jakarta, dengan frekuensi pencatatan terbanyak berada di Kecamatan Cengkareng (2.046 baris / 3,76%).

- titik_lokasi: Terdapat 1.737 nama lokasi unik (setelah pembersihan spasi pinggir) yang tersebar di 1.753 pasangan lokasi-kecamatan selama 31 hari.
- satuan_panjang/luas: Dari 32.388 baris yang terisi pada data mentah, terdapat 11 variasi penulisan dengan modus utama 'm' (30.504 baris / 94,18%). Dominasi satuan 'm' ini menjadi dasar penggunaan modus 'm' saat mengimputasi satuan yang kosong.

b) Statistik Deskriptif Lengkap Variabel Numerik

Berikut adalah ringkasan indikator pemusatan, penyebaran, kuartil, dan outlier pada nilai numerik yang valid sebelum dilakukan pembersihan dan imputasi:

Metrik Statistik	panjang/luas (Angka Valid Awal)	tanggal	volume_sampah_perhari(m3) (Angka Valid Awal)
Jumlah Data Valid (Count)	41.105	54.343	36.640
Missing / Noise Non-Angka	13.238	0	17.703
Rata-rata (Mean)	868,85	16,00	5,39
Standar Deviasi (Std)	1.500,81	8,94	5,50
Nilai Minimum (Min)	0,0875	1,00	0,00
Kuartil 1 (Q1 - 25%)	250,00	8,00	1,50
Median (Q2 - 50%)	650,00	16,00	3,00
Kuartil 3 (Q3 - 75%)	1.000,00	24,00	7,00
Nilai Maksimum (Max)	36.800,00	31,00	152,00

c) Perbandingan Mean vs Median Berdasarkan Wilayah

Untuk mengevaluasi ketimpangan distribusi ukuran lokasi dan volume sampah di setiap wilayah administratif, dilakukan perbandingan nilai rata-rata (*Mean*) dan nilai tengah (*Median*) pada data valid awal:

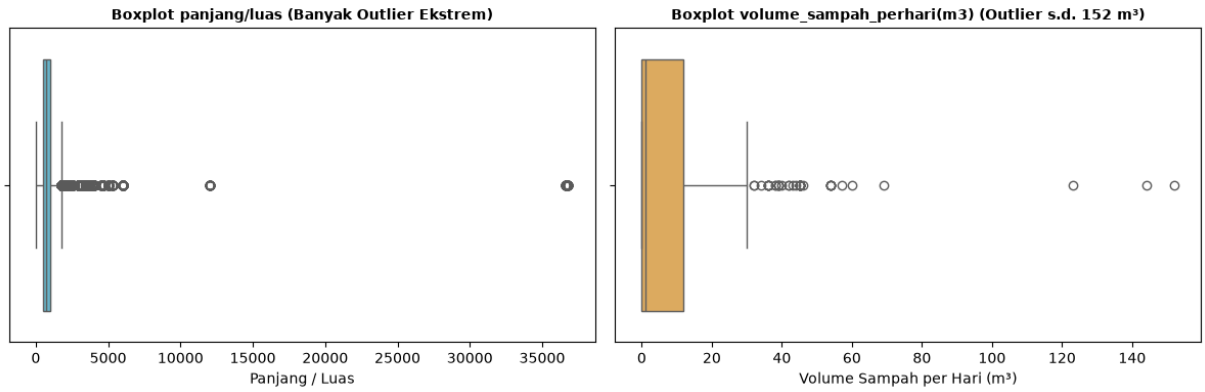
Wilayah	Mean Panjang/Luas	Median Panjang/Luas	Mean Volume (m^3)	Median Volume (m^3)	Karakteristik Distribusi Wilayah
Jakarta Barat	845,27	750,00	6,85	7,00	Kapasitas angkut tinggi (Mean < Median pada volume)
Jakarta Pusat	797,29	606,00	7,03	10,00	Kapasitas angkut tinggi (Mean < Median pada volume)
Jakarta Selatan	1.158,31	700,00	4,87	1,00	Miring ke kanan (Positively / Right-skewed)
Jakarta Timur	1.073,33	750,00	2,60	2,00	Miring ke kanan (Positively / Right-skewed)
Jakarta Utara	548,29	360,00	0,96	0,00	Miring ke kanan (Positively / Right-skewed)

Berdasarkan tabel di atas, terlihat dua temuan statistik yang sangat penting:

1. Pada variabel panjang/luas, seluruh wilayah memiliki nilai rata-rata (*Mean*) yang jauh lebih tinggi dibandingkan nilai tengah (*Median*) akibat adanya *outlier* sungai berukuran sangat panjang (mencapai 36.800 m).
2. Pada variabel volume_sampah_perhari(m3), terdapat perbedaan karakteristik kapasitas timbulan sampah yang sangat kontras antarwilayah, di mana Jakarta Pusat dan Jakarta Barat memiliki nilai tengah (*Median*) harian yang tinggi (10,00 m^3 dan 7,00 m^3, sedangkan Jakarta Selatan, Timur, dan Utara memiliki *Median* yang jauh lebih rendah (0,00 m^3 hingga 2,00 m^3) namun dengan *Mean* yang tertarik ke atas oleh *outlier* (hingga 152 m^3).

Kedua fakta ini membuktikan bahwa pengisian *missing values* tidak boleh dipukul rata menggunakan satu angka rata-rata (*Mean*) global untuk seluruh Jakarta, melainkan harus

menggunakan Median per Kelompok Titik Lokasi / Kecamatan (*Group Median Imputation*) agar tahan terhadap *outlier* sekaligus menjaga karakteristik asli di setiap wilayah.



Visualisasi boxplot di atas menunjukkan adanya pencilan (outliers) ekstrem pada variabel panjang/luas dan volume_sampah_perhari(m3). Sebagian besar data terkonsentrasi pada rentang nilai yang relatif rendah, sedangkan nilai pencilan membentang jauh ke kanan. Kemiringan distribusi ini memperkuat alasan penggunaan nilai median sebagai acuan imputasi data hilang.

3. Temuan Permasalahan Kualitas Data (Data Quality Issues)

Berdasarkan hasil inspeksi menyeluruh pada seluruh variabel di dataset mentah, ditemukan beberapa permasalahan kualitas data yang harus ditangani:

1. **Ketidaksesuaian Tipe Data Numerik:** Kolom panjang/luas dan volume_sampah_perhari(m3) masih terbaca sebagai tipe teks (object) karena terkontaminasi huruf satuan, karakter garis miring, teks tanggal Excel, dan simbol strip.
2. **Noise & Inkonsistensi pada Kolom panjang/luas:**
    - Terdapat 868 baris kosong (NaN) secara eksplisit.
    - Terdapat satuan yang menempel langsung pada angka, yaitu '800m', '600m', '500m', '400m' (279 baris) dan '1Ha' (62 baris).

- Terdapat 11.749 baris berformat dimensi gabungan Panjang/Lebar yang menggunakan garis miring (contoh: '3500/70', '1000/10').
- Terdapat 341 baris berisi teks korup akibat format tanggal otomatis di Excel ('Apr-00', 'May-00', 'Jun-00', 'Oct-00', 'Apr-21', 'Apr-50', 'May-50') serta tanda strip ('-').
- Terdapat 28 lokasi di Kecamatan Kebon Jeruk yang mengalami inkonsistensi pencatatan antar-tanggal, di mana pada tanggal 1 tertulis 1360 (satuan M), namun pada tanggal 2–31 tertulis 1.36 tanpa satuan.

3. **Inkonsistensi & Missing Values pada Kolom satuan_panjang/luas:**
   - Memiliki 21.955 baris kosong (NaN / 40,40%).
   - Terpecah ke dalam 11 variasi penulisan satuan yang tidak seragam (m, M, Ha, H, HA, hektar, Hektar, m2, m², M³, km).
4. **Noise & Missing Values Tersembunyi pada Kolom volume_sampah_perhari(m3):**
   - Terdapat kesalahan ketik (*typo*) huruf 'O.5' (huruf O kapital, bukan angka nol 0.5) sebanyak 1 baris.
   - Terdapat 17.702 baris berisi simbol penanda kosong berupa tanda strip biasa '-' (15.649 baris), karakter *em-dash* Windows '\x97' (2.050 baris), dan spasi kosong ' ' (3 baris).

4. Tahap 2: Pembersihan Noise & Konsistensi Kolom

Pada tahap ini dilakukan pembersihan *noise* tanpa menghapus baris data harian, diikuti penyeragaman isi kolom agar konsisten:

4.1 Pemisahan Satuan Menempel & Parsing Dimensi panjang/luas

- **Pemisahan Satuan Menempel:** Pada 341 baris yang memiliki akhiran huruf (800m, 600m, 500m, 400m, 1Ha), teks satuannya dipindahkan ke kolom satuan_panjang/luas, sedangkan pada kolom panjang/luas disisakan angkanya saja.
- **Parsing Format Panjang/Lebar (/):** Pada 11.749 baris yang memuat tanda garis miring (seperti 3500/70), diambil angka pertama di sebelah kiri tanda / (3500) sebagai

nilai panjang utama ruas kali, dan kolom satuan_panjang/luas yang kosong diisi dengan satuan 'm'.

- **Konversi Noise Tanggal Excel ke NaN:** Sebanyak 341 baris yang berisi teks tanggal Excel (Apr-00, May-50, -, dll.) diubah menjadi np.nan, kemudian seluruh isi kolom panjang/luas dikonversi menjadi tipe numerik float64.

4.2 Standarisasi Satuan & Konsistensi Antar-Tanggal per Lokasi

- **Penyeragaman 11 Variasi Satuan Menjadi 5 Satuan Baku:** Penulisan satuan yang bermakna sama diseragamkan menjadi 5 satuan standar, yaitu **'m'** (dari m, M), **'Ha'** (dari Ha, H, HA, hektar, Hektar), **'m2'** (dari m2, m²), **'m3'** (dari M³), dan **'km'**. Satuan ini tidak dijadikan 1 satuan tunggal karena kolom panjang/luas mencatat objek badan air dengan dimensi fisik yang berbeda (dimensi **panjang** m, km untuk sungai/kali; dimensi **luas** Ha, m2 untuk waduk/situ; dan dimensi **volume** m3), di mana satuan luas tidak dapat dikonversi secara matematis menjadi satuan panjang.
- **Penyelarasan Nilai & Satuan Antar-Tanggal (Tanggal 1 s.d. 31):** Karena ukuran fisik suatu lokasi kali/waduk bersifat tetap sepanjang bulan Januari 2021, dilakukan pengelompokan berdasarkan titik_lokasi dan kecamatan untuk menyebarkan satuan dari tanggal 1 ke tanggal 2–31 (.ffill().bfill()) serta menyamakan nilai panjang/luas menggunakan nilai maksimum lokasi (.transform('max')), sehingga kasus desimal 1.36 di Kecamatan Kebon Jeruk kembali konsisten menjadi 1360 meter.

4.3 Pembersihan Noise pada Kolom volume_sampah_perhari(m3)

- Karakter typo 'O.5' diperbaiki menjadi '0.5'.
- Seluruh simbol strip ('-', '\x97', dan ' ') sebanyak **17.702 baris** diubah menjadi np.nan, lalu kolom dikonversi ke tipe numerik float64.

5. Tahap 3: Penanganan / Imputasi Missing Values

Setelah seluruh *noise* diubah menjadi NaN, dilakukan pengisian nilai kosong menggunakan metode yang sesuai dengan distribusi dan konteks spasial data:

1. Imputasi Kolom satuan_panjang/luas (Menggunakan Modus): Sisa baris yang masih belum memiliki satuan setelah penyelarasan antar-tanggal diisi menggunakan Modus yaitu 'm', karena lebih dari 96% titik lokasi merupakan ruas kali/saluran berdimensi panjang (meter).
2. Imputasi Kolom panjang/luas (Menggunakan Median per Kecamatan): Terdapat 29 titik lokasi *Saringan Sampah* (899 baris) yang tidak memiliki ukuran panjang/luas sama sekali selama 31 hari. Nilai kosong ini diimputasi menggunakan Median panjang/luas dari kecamatan tempat lokasi tersebut berada agar tidak terdistorsi oleh *outlier*.
3. Imputasi Kolom volume_sampah_perhari(m3) (Median per Titik Lokasi & Fallback 0 MNAR):
    - Tahap Pertama (MAR): Nilai kosong pada tanggal tertentu diisi menggunakan Median volume sampah harian dari titik_lokasi dan kecamatan yang sama pada hari-hari lainnya di bulan Januari 2021.
    - Tahap Kedua (MNAR Fallback 0): Apabila suatu titik_lokasi tercatat strip ('-') selama 31 hari penuh (tidak memiliki riwayat pengangkutan sama sekali sepanjang bulan), maka nilainya diisi dengan angka 0 karena mengindikasikan tidak adanya aktivitas pengangkutan sampah di lokasi tersebut.

6. Tahap 4: Hasil Akhir Statistik Deskriptif & Perbandingan Preprocessing

Setelah seluruh tahapan pembersihan dan imputasi selesai, dihasilkan dataset yang 100% bersih (54.343 baris, 0 *missing values*) dan disimpan ke dalam file Excel volume_pengangkutan_sampah_preprocessed.xlsx.

Tabel 6.1 — Perbandingan Kondisi Dataset Sebelum dan Sesudah Preprocessing:

Komponen Evaluasi	Sebelum Preprocessing (Data Mentah)	Sesudah Preprocessing (Data Bersih)
Tipe Data panjang/luas & Volume	object (teks tercampur huruf, /, tanggal Excel, & -)	float64 (numerik desimal standar)

Missing & Noise panjang/luas	868 NaN + 341 tanggal Excel + 11.749 '/' + 341 satuan menempel + 28 lokasi inkonsisten	0 NaN (Konsisten per lokasi & diimputasi dengan Median Kecamatan)
Missing Values satuan_panjang/luas	21.955 baris kosong (40,40%)	0 NaN (Diselaraskan per lokasi & diimputasi dengan Modus 'm')
Konsistensi Satuan Ukuran	Terpecah dalam 11 variasi penulisan (m, M, Ha, H, HA, hektar, Hektar, m2, m², M³, km)	Terseragamkan menjadi 5 satuan baku (m: 52.638, Ha: 1.581, m2: 62, m3: 31, km: 31)
Noise volume_sampah_perhari(m3)	17.702 baris simbol strip ('-', '\x97', ' ') & 1 baris typo 'O.5'	0 NaN (Diimputasi dengan Median per Titik Lokasi & 0 untuk MNAR)

Tabel 6.2 — Statistik Deskriptif Akhir Dataset Bersih (54.343 Baris):

Variabel Numerik	Count	Mean (Rata-rata)	Median (Q2)	Minimum	Maksimum	Standar Deviasi
panjang/luas	54.343	929,37	700,00	0,0875	36.800,00	1.418,23
volume_sampah_perhari(m3)	54.343	4,06 m^3	2,00 m^3	0,00 m^3	152,00 m^3	4,97 m^3

7. Kesimpulan Akhir Preprocessing

Prosedur *preprocessing* data berbasis kerangka kerja CRISP-DM telah berhasil mentransformasi dataset mentah pengangkutan sampah kali, sungai, situ, dan waduk DKI Jakarta bulan Januari 2021 (54.343 baris × 8 kolom) menjadi dataset yang bersih, konsisten,

dan valid secara statistik. Seluruh *noise* (satuan menempel, format Panjang/Lebar, korupsi tanggal Excel, typo 'O.5', dan 17.702 simbol strip) telah berhasil dibersihkan, 11 variasi penulisan satuan telah diseragamkan menjadi 5 satuan baku sesuai dimensi fisiknya, dan seluruh *missing values* telah diimputasi secara kontekstual hingga mencapai 0 NaN. Dari data bersih ini juga diperoleh informasi bahwa Jakarta Barat merupakan wilayah dengan total volume pengangkutan sampah tertinggi sepanjang Januari 2021 sebesar 107.371,5 m^3, diikuti oleh Jakarta Selatan sebesar 38.193,9 m^3. Dataset akhir telah disimpan ke dalam file Excel dan siap digunakan untuk analisis lebih lanjut.

Link Dataset: https://drive.google.com/drive/folders/1yWLl_qDp08YhSn0GQXwpFK4tUk1uHYnC?usp=sharing

Link Repo: https://github.com/Axcelion017/Pengantar-Sains-Data-CS5/tree/main/Tugas/Tugas-2/Soal1