TUGAS 2

Ganjil 2025/2026 – CS

Nama : NIM:

Mata Kuliah - Kode Mata Kuliah	**Pengantar Sains Data - 52305**
Hari, tanggal - Kelas	**Senin, 20 Oktober 2025 - CS5**
Waktu - Sifat	**Deadline 22 Oktober 2025 pukul 10.00**
Dosen/Koordinator Mata Kuliah	**Dr. Ariana Yunita**

Instruksi pengerjaan:

- Tugas 2 terdiri dari 2 soal
- Jelaskan secara rinci langkah-langkah pengerjaan

1. Terdapat suatu data "Volume Pengangkutan Sampah di Kali Sungai Situ Waduk Bulan Januari Tahun 2021"

   Penjelasan variabel data ini berisi antara lain :

1. bulan : Bulan
2. titik_lokasi : Titik Lokasi Penampungan Sampah
3. kecamatan : Kecamatan dimana titik lokasi penampungan sampah berada
4. wilayah : Wilayah dimana titik lokasi penampungan sampah berada
5. panjang/luas : Panjang atau luas area penanganan sampah
6. satuan : Satuan Panjang atau Luas
7. tanggal : Tanggal
8. volume_sampah_perhari (m3) : Volume Sampah per Hari (dengan satuan m3)

Data tersebut adalah data mentah yang masih kotor karena terdapat banyak noise. Lakukan pre- processing yaitu **mengatasi noise** (membuat data tidak konsisten menjadi konsisten) dan **mengisi missing value** terhadap dataset tersebut. (HINT: Anda dapat melakukan konsistensi data terlebih dahulu, misal mengatasi perbedaan pada kolom "satuan_panjang/luas".

Nama : NIM:

Konsistensikan dengan nilai “panjang/luas”.) Berikan penjelasan langkah-langkah pengerjaan dan asumsi untuk penyelesaian soal tersebut. Penjelasan dapat disertai dengan diagram.

Anda dapat menggunakan Bahasa pemrograman Python dan beberapa libraries seperti pandas. Jika Anda menggunakan alat bantu lainnya, misal Ms Excel, jelaskan urutan-urutan pengerjaannya.

2. Diberikan dataset terkait turbin angin.
   a. Identifikasi masalah pada kolom "No" dalam dataset. Buat fungsi Python untuk menstandarisasi penomoran ulang dataset secara berurutan mulai dari 1 hingga n (jumlah total record).
   b. Lakukan pengecekan missing values pada seluruh kolom dataset. Tampilkan jumlah missing values per kolom dalam bentuk tabel.
   c. Validasi tipe data setiap kolom. Jika ditemukan tipe data yang tidak sesuai, lakukan konversi ke tipe data yang tepat dan jelaskan alasannya.
   d. Kelompokkan County berdasarkan region geografis Ireland:

   West: Galway, Mayo, Clare, Limerick, Kerry

   South: Cork, Waterford

   East: Wexford

   North: Donegal, Sligo, Leitrim, Cavan

   Midlands: Tipperary, Offaly, Roscommon

   Buat kolom "Region" dan hitung total installed capacity per region.
   e. Buatlah kolom baru bernama "Capacity_per_Turbine" yang menghitung rata-rata kapasitas (MW) per turbine untuk setiap proyek. Tampilkan 5 proyek dengan efisiensi tertinggi dan terendah.
   f. Kategorikan proyek wind farm berdasarkan skala:

Nama : NIM:

Small: < 20 MW

Medium: 20-60 MW

Large: > 60 MW

g. Buatlah kolom "Time_Period" yang mengelompokkan tahun instalasi ke dalam periode:

Early (1997-2005)

Growth (2006-2012)

Expansion (2013-2020)

Analisis bagaimana distribusi "Project_Scale" berubah antar periode.

h. Buat pivot table dengan County sebagai index, Year sebagai columns, dan sum of Installed Capacity sebagai values. Identifikasi tahun-tahun paling produktif untuk setiap county.

i. Kapasitas turbine angin modern umumnya berkisar antara 1.5 - 3.5 MW per turbine. Identifikasi proyek-proyek yang memiliki "Capacity_per_Turbine" di luar range normal ini. Apakah ada indikasi data entry error?

j. Gunakan metode IQR (Interquartile Range) untuk mendeteksi outlier pada kolom "Installed Capacity" dan "No of Turbines". Tampilkan record-record yang teridentifikasi sebagai outlier.

k. Hitung korelasi antara "Installed Capacity" dan "No of Turbines". Visualisasikan scatter plot dan identifikasi proyek-proyek yang menyimpang dari pola umum.

l. Lakukan normalisasi pada kolom "Installed Capacity" menggunakan Min-Max Scaler (range 0-1). Tampilkan 5 nilai asli dan hasil normalisasinya.

m. Distribusi "Installed Capacity" kemungkinan right-skewed. Lakukan log transformation dan bandingkan distribusi sebelum dan sesudah transformasi menggunakan histogram.

Nama : NIM:

n. Lakukan One-Hot Encoding pada kolom "Country". Berapa jumlah kolom baru yang dihasilkan? Tampilkan 5 baris pertama dari hasil encoding.

o. Hitung growth rate (year-over-year) untuk total installed capacity. Identifikasi tahun dengan pertumbuhan tertinggi dan terendah. Apa yang mungkin menjadi penyebabnya?

p. Buatlah market concentration analysis: Hitung persentase kontribusi top 5 countries terhadap total installed capacity nasional. Apakah pasar wind energy di Ireland terkonsentrasi atau tersebar merata?

"Education is not preparation for life; education is life itself." – John Dewey